

计算物理
Chinese Journal of Computational Physics
ISSN 1001-246X, CN 11-2011/O4

《计算物理》网络首发论文

题目: 基于物理信息神经网络的实际气体状态方程预测模型
作者: 李起锋, 娄钦
收稿日期: 2025-09-16
网络首发日期: 2025-12-18
引用格式: 李起锋, 娄钦. 基于物理信息神经网络的实际气体状态方程预测模型[J/OL]. 计算物理. <https://link.cnki.net/urlid/11.2011.O4.20251217.1614.004>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

基于物理信息神经网络的实际气体状态方程预测模型

李起锋, 娄钦[✉]

(上海理工大学能源与动力工程学院, 上海 200093)

*通信作者 娄钦, 女, 教授, 博士生导师, 研究方向为基于物理信息约束深度学习 E-mail: louqin560916@163.com

摘要 本文基于物理信息神经网络 (physics informed neural networks, PINN) 方法提升 Redlich-Kwong-Soave (RKS) 和 Peng-Robinson (PR) 状态方程 (EOS) 在复杂工况下的泛化能力。具体地说, 以水蒸气为研究对象, 在 RKS 与 PR 方程中引入高阶体积项 (ρ^3), 并依据饱和水蒸气的压力、密度、温度实验数据以及不同参数满足的物理规律, 优化高阶项系数, 构建基于物理信息神经网络的实际气体状态方程预测模型。数值结果表明方程约束神经网络模型提升了水蒸气两相行为的预测精度, 相较于原始的 RKS 和 PR 状态方程, 方程约束神经网络模型对于不同压力下密度的预测精度分别提高了 7.775% 和 4.33%, 尤其是在气相区, 它们的预测误差分别降低到了 0.93% 和 1.63%。此外, 状态方程的定温线图验证了方程约束神经网络模型具有良好的物理一致性。

关键词 RKS 方程; PR 方程; 水蒸气; 物理信息神经网络

中图分类号 TK123; TP183 **文献标志码** A

Prediction Model of Real Gas Equation of State Based on Physics-Informed Neural Networks

LI Qifeng, LOU Qin[✉]

(School of Energy and Power Engineering, University of Shanghai for Science and Technology, Shanghai 200093, China)

Abstract This work improves the generalization capability of Redlich-Kwong-Soave (RKS) and Peng-Robinson (PR) equation of state (EOS) under complex working conditions using the physics-informed neural network (PINN) model. In particular, a high-order volume term (proportional to ρ^3) is introduced into the RKS and PR equations using water vapor as the research subject. The coefficient of the higher-order term is optimized to construct a PINN-based prediction model for real gas EOS by leveraging experimental data on the pressure, density, and temperature of saturated water vapor, as well as the physical constraints satisfied by these parameters. Numerical findings demonstrate that the PINN-based prediction model improves the prediction accuracy of two-phase behavior. Compared to the original RKS and PR EOS, the predictive accuracy for density obtained by the PINN-based prediction model has improved by 7.775% and 4.33%, respectively. Particularly in the vapor phase region, their prediction errors are reduced to 0.93% and 1.63%. Additionally, the physical consistency of PINN-based prediction model is confirmed by isothermal diagrams of the equation of state.

Key words Redlich-Kwong-Soave Equation; Peng-Robinson Equation; water vapor; physics informed neural networks

0 引言

状态方程作为描述物质在不同温度、压力和体积条件下热力学行为的工具, 其准确性直接关乎工程应用的可靠性。在环境工程、油气工程、化工模拟等众多领域状态方程都发挥着重要作用^[1-3]。在众多状态方程中, Redlich-Kwong-Soave (RKS) 与 Peng-Robinson (PR) 方程凭借适用范围广以及参数易于获取的优势, 对非极性 & 弱极性流体的两相行为预测方面展现出优异性能, 得到了工业界和学术界广泛认可和应用^[4]。然而, 这两种方程存在一定缺陷。在高温高压工况或者强极性流体 (如水蒸气) 等复杂应用场景中, 由于其分子尺寸较小、氢键丰富、静电相互作用显著, 导致流体的密度变化

收稿日期: 2025-09-16

基金项目: 国家自然科学基金项目 (52376068, 51976128)

作者简介: 李起锋, 男, 硕士研究生, 研究方向为机器学习 E-mail: fengfengql@163.com

网络首发时间: 2025-12-18 15:15:51 网络首发地址: <https://link.cnki.net/urlid/11.2011.04.20251217.1614.004>

规律不同于常规简单流体,此时 RKS 方程和 PR 方程的预测精度出现明显下降^[5-7],难以满足高精度工程计算的需求,从而在一定程度上制约了其在复杂工况中的应用潜力。

为改进两类气体状态方程的适用范围与预测精度,研究人员已提出多种优化方案。Luo 等^[8]基于 RKS 状态方程对纯物质饱和蒸气压力的计算结果,对方程吸引项中的温度修正函数 $\alpha(T)$ 进行修正,将修正后的状态方程应用于 37 种物质的相关预测时,其平均预测精度较原方程提升了 0.848%。Hajizadeh 等^[9]则通过推导构建了含新型排斥相参数 b 的 SRK-EOS (Soave-Redlich-Kwong) 方程,并将该改进方程用于沥青质沉淀模型的模拟计算,结果表明,模拟数据与实验数据具有良好的一致性。此外, Li 等^[10]通过开发无中心因子的新型温度修正函数 $\alpha(T)$,进一步提升了蒸气压力预测的准确性; Eslami 等^[11]则引入与温度降低相关的校正因子,所建立的多参数模型能够精准再现实验测得的饱和液体密度与蒸气压力数据。尽管上述方案在气体状态方程的性能优化方面均取得了阶段性进展,但仍存在显著局限性:一方面,通过修改温度修正参数实现的优化,可能导致模型在不同温度区间的通用性下降;另一方面,多参数模型虽能有效提升预测精度,但其参数确定过程复杂度较高,需依赖大量实验数据作为支撑^[12]。

近年来,随着人工智能技术的快速发展,基于物理信息的神经网络 (Physics-Informed Neural Networks, PINN) 作为一种新兴的计算方法,在数学物理方程求解领域展现出重要的应用价值^[13]。该方法将物理定律集成到损失函数中,不仅可以灵活地处理复杂边界条件的物理问题,而且可以集成多物理场信息,为流体力学领域的数值求解提供了新的研究思路^[14,15]。此外, PINN 能够在有限的实验数据条件下,学习并构建满足物理约束的网络关系,从而在保证模型准确拟合能力的同时,兼顾了物理一致性^[16,17]。目前, PINN 在复杂积分方程求解、多介质流体动力学模拟以及激光转塔气动光学效应预测等领域展现出良好的应用前景^[18-21]。

鉴于此,本工作采用 PINN 模型,并结合少量测量数据构建实际气体状态方程,为实际气体密度、压力和温度之间的关系提供更为准确的数值模型。

1 模型和方法

物理信息神经网络是一种将物理模型与深度学习相结合的计算方法,该方法通过将控制方程及相关运动学、热力学约束条件的残差作为惩罚项引入损失函数,实现了物理定律与神经网络架构的有效融合。值得注意的是,该方法可根据实际需求对各项约束条件进行加权处理,并能灵活整合各种测量数据进行模型训练,构建待求物理量和已知变量之间的流体动力学模型^[22]。研究表明,在涉及部分时空离散测量数据的反问题求解方面, PINN 相较于传统计算流体力学求解器展现出显著的预测精度优势和计算效率提升。特别地, PINN 采用正问题与反问题相统一的数学表述形式,这一特性有效突破了传统流动优化与设计研究中长期存在的计算瓶颈问题。

本节系统阐述基于物理信息神经网络的实际气体状态方程求解方法的理论框架与实现过程。首先,基于维里方程构建修正后的气体状态方程^[23],通过引入高阶项提升模型对复杂气体体系的描述能力。其次,将详细介绍气体状态方程的物理信息神经网络模型的实现方法,包括:(1)测量数据的预处理以及神经网络模型构架;(2)融合测量数据和物理约束条件的损失函数设计以及基于梯度优化的训练策略。

1.1 气体状态方程

在工业热力学计算中,状态方程被广泛应用于纯物质的热力学性质的描述^[24]。目前,常用的状态方程包括 Van der Waals (vdW) 方程、Redlich-Kwong (RK) 方程、RKS 方程、PR 方程^[25-28]。其中 RKS 状态方程是在 RK 方程基础上的改进模型,该方程通过引入温度相关函数 $\alpha(T)$ 修正吸引力项^[29],显著提高了对烃类等非极性物质气液平衡的预测精度;PR 状态则通过进一步优化 $\alpha(T)$ 函数,在临界区域的气液平衡预测方面表现出更优越的性能。RKS 方程和 PR 都是三参数状态方程^[30,31](以 T_c , P_c , ω 为特征参数),其数学形式均包含两项:一项描述分子间的体积排斥效应,另一项表征分子间的吸引作用。其中 RKS 的形式如下:

$$p = \frac{\rho RT}{1 - b\rho} - \frac{a\alpha(T)\rho^2}{1 + b\rho}, \quad (1)$$

其中, p 为压力, ρ 为密度, T 为绝对温度, R 为通用气体常数。 a 为吸引项参数, 反映分子间相互吸引力的大小; b 为排斥项参数, 反映分子大小及排斥作用, 使分子不能无限靠近; $\alpha(T)$ 为温度修正函数, 是用来描述吸引力随温度变化的修正因子, 其形式如下:

$$\alpha(T) = \left[1 + (0.480 + 1.574\omega - 0.176\omega^2) \left(1 - \sqrt{\frac{T}{T_c}} \right) \right]^2, \quad (2)$$

其中 ω 为偏心因子, 表征分子非球形程度。RKS 方程中参数 a 和 b 与临界温度 T_c 以及临界压力 P_c 之间的关系如下:

$$a = \frac{0.42748R^2T_c^2}{P_c}, \quad b = \frac{0.08664RT_c}{P_c}, \quad (3)$$

PR 方程形式为公式 (4) 所示:

$$p = \frac{\rho RT}{1 - b\rho} - \frac{a\alpha(T)\rho^2}{1 + 2b\rho - b^2\rho^2}, \quad (4)$$

其中, a 和 b 也分别为反映分子间吸引作用和排斥作用的参数; $\alpha(T)$ 为如下形式的温度修正函数:

$$\alpha(T) = \left[1 + (0.37464 + 1.54226\omega - 0.26992\omega^2) \left(1 - \sqrt{\frac{T}{T_c}} \right) \right]^2, \quad (5)$$

通过改进 $\alpha(T)$, PR 方程在温度依赖性上更加灵活, 能够更准确描述气液密度和共存曲线, 尤其适用于非理想复杂流体的热力性质描述。PR 方程中的参数 a 和 b 与临界温度和临界压力之间的关系如下:

$$a = \frac{0.45724R^2T_c^2}{P_c}, \quad b = \frac{0.0778RT_c}{P_c}, \quad (6)$$

注意到 RKS 状态方程和 PR 状态方程均可以表示成维里展开形式, 且两个状态方程均考虑了 ρ^1 , ρ^2 , 以及 ρ^3 项, 但其高阶项的系数是由经验参数间接确定的, 并未显式反映高温高压条件下增强的多体相互作用。这一简化处理会导致在高温高压工况下存在预测精度不足的问题。这是因为在该工况下, 气体密度显著增大, 分子间距缩小, 三个或更多分子同时相互作用的多体效应变得不可忽略。此类多体相互作用无法由仅含双体作用的经典状态方程描述。为了提高以上方程的预测能力, 本工作修正了密度的高阶项 (ρ^3) 系数, 以显式表征高阶分子关联对压力的贡献。

以 RKS 方程为例, 修改后的方程形式为:

$$p = \frac{\rho RT}{1 - b\rho} - \frac{a\alpha(T)\rho^2}{1 + b\rho} + c\rho^3, \quad (7)$$

这里 c 为待求系数, 为了保证结果的一般性以及方便与前人文献做对比, 基于对比态定律, 本文中所有物理量均采用无量纲形式, 无量纲量和实际物理量之间的关系如下:

$$\rho_R = \frac{\rho}{\rho_c} = \frac{\rho^{\text{real}}}{\rho_c^{\text{real}}}, \quad P_R = \frac{P}{P_c} = \frac{P^{\text{real}}}{P_c^{\text{real}}}, \quad T_R = \frac{T}{T_c} = \frac{T^{\text{real}}}{T_c^{\text{real}}}, \quad (8)$$

其中下标“R”和“c”分别表示约化性质和临界性质, 上标 real 代表真实的物理单位。通过这种方式, 使用归一化性质的概念^[32]可以很容易地将这些值与真实的物理参数联系起来, 并将真实单位转换为无量纲单位。在本文中, RKS 状态方程和 PR 状态方程中参数设置^[33]为 $a=2/49$, $b=2/21$, $R=1$ 。

1.2 基于物理信息神经网络的状态方程模型

1.2.1 测量数据的预处理以及方程约束神经网络模型构架

在构建方程约束神经网络模型前, 首先对测量数据进行预处理操作, 为了保持一致性, 本文所研究的 RKS-PINN 模型和 PR-PINN 模型均采用相同的实验数据集。本研究选取了温度范围为 273.16K 至 643.16K 的饱和水蒸气作为研究对象, 其热力学性质数据来源于 NIST Chemistry WebBook 官网, 该数据库可提供压力、温度、密度等关键参数的高精度实验数据^[34]。为降低量纲差异对模型训练的干扰, 对实验数据进行了归一化处理, 并按照 7:3 的比例将实验数据集划分为训练集与测试集, 用于后续的模型训练。

在本文提出的方程约束神经网络模型中, 构建了一个基于物理信息的神经网络, 用于建立已知变量 (T, ρ) 与待求物理量 (p, c) 之间的非线性映射关系。以 RKS-PINN 模型为例, 该映射关系通过一个全连接神经网络实现, 其数学表达式如式 (9) 所示:

$$(p, c) = f_{NN}(T, \rho; \mathbf{w}, \mathbf{b}), \quad (9)$$

其中, (T, ρ) 为网络的输入变量, (p, c) 为输出变量, $\mathbf{w}$ 和 $\mathbf{b}$ 分别表示神经网络中待优化的权重矩阵和偏置向量, f_{NN} 代表具有两个输入节点和两个输出节点的全连接神经网络^[35]。

该神经网络结构包含 L 层, 第 i 层的节点数为 M_i 。输入层 (第 0 层) 设有两个节点 ($M_0=2$) 负责接收温度和密度 (T, ρ) 数据, 输出层 (第 L 层) 同样设有两个节点 ($M_L=2$) 负责输出压力和待求系数 (p, c) 。其他中间层称为隐藏层, 任务是对不同类型的数据进行非线性变换。每个结点的输入 $\mathbf{v}^i$ 等于上一个结点 $\mathbf{v}^{i-1}$ 经过非线性变换后的输出, 信息在神经网络中的传播过程遵循如下公式:

$$\mathbf{v}^i = \sigma(\mathbf{w}^i \mathbf{v}^{i-1} + \mathbf{b}^i), \quad i = 1, 2, \dots, L, \quad (10)$$

其中, $\mathbf{v}^i$ 、 $\mathbf{w}^i$ 和 $\mathbf{b}^i$ 分别是第 i 层网络的状态向量、权重矩阵和偏差向量, σ 是非线性激活函数。本文采用双曲正切 ($\tanh$) 激活函数^[36], 其定义如公式 (11) 所示:

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}, \quad (11)$$

该函数具有良好的平滑性和对称性, 有助于梯度传播和模型收敛。

网络训练采用反向传播算法结合梯度下降优化器^[37], 通过最小化损失函数来迭代更新所有权重和偏置参数。为了确保模型不仅拟合数据, 更严格遵守物理规律, 在临界点附近引入了物理约束^[38]。根据热力学理论, 状态方程在临界点处需满足以下数学条件:

$$\left(\frac{\partial P}{\partial V} \right)_{T_c} = 0, \quad (12)$$

$$\left(\frac{\partial^2 P}{\partial V^2} \right)_{T_c} = 0, \quad (13)$$

其中, 比体积 $V=1/\rho$ 。这两个条件确保了在临界点处压力对体积的一阶和二阶偏导数为零, 这是临界点的定义特征。

此外, 损失函数包含数据驱动约束项, 其表达式如式 (14) 所示, 旨在最小化神经网络预测压力值 p_{NN} 与真实压力值 p_{true} 之间的误差。

$$p_{NN} - p_{true} = 0, \quad (14)$$

根据上述映射关系与控制方程约束, 建立方程约束神经网络模型, 包含 RKS-PINN 框架和 PR-PINN 框架, 图 1 所示为 RKS-PINN 框架。在每一次迭代过程中, 模型首先通过神经网络得到已知变量与待求物理量的函数映射关系; 随后将状态方程的修正形式作为物理约束项嵌入损失函数, 并通过自动微分技术^[39]计算状态方程的一阶、二阶导数, 强化临界点附近的行为约束; 再由物理约束方程和数据驱动约束确定总损失值, 优化器根据总损失值对神经网络的参数进行优化, 各损失项权重采用 GradNorm 策略^[40]进行自适应调整, 避免训练过程中出现某项被压制或主导的现象。上述过程将被反

复执行，通过不断更新模型参数，如网络权重和偏差最小化 $Loss$ 函数，可以得到目标变量和输入变量之间的函数关系。




图 1 数据输入的方程约束神经网络模型
Fig.1. Equation constrained neural network model for data input

1.2.2 损失函数和优化方法

根据控制方程式(12)~式(14)，可给出 RKS-PINN 模型各方程 MSE 损失函数的表达形式为

$$LOSS_{LD} = \frac{1}{N} \sum_{i=1}^N [p_{NN}^i - p_{true}^i]^2, \quad (15)$$

$$LOSS_{GE} = \frac{1}{N} \sum_{i=1}^N \left[p_{NN}^i - \left(\frac{\rho^i RT^i}{1 - b\rho^i} - \frac{a\alpha(T^i)(\rho^i)^2}{1 + b\rho^i} + c(\rho^i)^3 \right) \right]^2, \quad (16)$$

$$LOSS_{FD} = \frac{1}{N} \sum_{i=1}^N \left[\left(\frac{\partial p_{NN}}{\partial V} \right)_{T_c}^i \right]^2, \quad (17)$$

$$LOSS_{SD} = \frac{1}{N} \sum_{i=1}^N \left[\left(\frac{\partial^2 p_{NN}}{\partial V^2} \right)_{T_c}^i \right]^2, \quad (18)$$

其中，数据拟合项 $LOSS_{LD}$ 用于衡量模型输出与实验数据之间的差异，确保网络能够有效拟合训练数据；物理方程约束项 $LOSS_{GE}$ 在原气体状态方程形式基础上加入高阶项作为控制方程，保证模型输出满足物理规律；模型还引入了一阶导数约束项 $LOSS_{FD}$ 和二阶导数约束项 $LOSS_{SD}$ ，用于约束输出函数在临界点区域的物理一致性。

最终的总损失函数为上述各项的加权和为

$$Loss = LOSS_{LD} + LOSS_{GE} + LOSS_{FD} + LOSS_{SD}, \quad (19)$$

在神经网络训练中，当总损失函数 $Loss$ 确定后，模型的权重与偏差参数可通过随机梯度下降算法的迭代更新实现总损失函数的逐步降低。为进一步提升参数优化效率，训练过程中引入了两种性能优异的优化器—Adam 优化器^[41]与 L-BFGS 优化器^[42]，二者均能通过高效的参数更新机制实现损失函数最小化，为模型收敛提供有力支撑。为加速训练进程并兼顾优化效果，本研究采用 Adam 与 L-BFGS 组合的分阶段优化策略：在初始训练阶段，优先使用 Adam 优化器进行参数迭代，利用其收敛速度快、对初始参数鲁棒性强的特点，快速将模型损失降至预设阈值以下，当损失满足阈值条件后，

切换至 L-BFGS 优化器继续优化, 凭借其在局部最优解搜索中的高精度优势, 进一步微调模型参数, 整个训练过程终止条件设定为: 当总训练损失进入平稳期 (即连续迭代中损失不再显著下降), 或迭代次数达到预设最大步数时, 判定模型训练完成; 该组合策略充分发挥了两种优化器的互补优势—Adam 的快速收敛特性与 L-BFGS 的高精度微调特性形成有效协同, 不仅显著提升了模型的收敛效率, 还进一步增强了模型最终的预测精度与训练过程的稳定性。

2 结果与分析

本章首先评估神经网络参数配置对求解气体状态方程的物理信息神经网络模型精度的影响。其次评估方程约束神经网络模型预测精度; 最后则通过对比不同方程的 p - V 曲线, 更直观地展示方程约束神经网络模型不同温压条件下求解气体热力学性能的表现。

2.1 方程约束神经网络模型网络参数评估

为探究深度学习神经网络结构参数对状态方程建模精度与物理一致性的影响, 基于方程约束神经网络模型框架, 构建了不同深度和宽度的网络并评估其训练性能。具体来说, 隐藏层设置为 2、3、4 和 5 层四种情况, 每层 16、32 和 64 神经元个数, 共形成 12 种深度学习网络配置。所有网络在相同学习率下训练 15000 次评估模型网络参数对于模型性能的影响。

2.1.1 RKS-PINN 模型

对于 RKS-PINN 模型, 优化初期采用 Adam 算法, 结合梯度裁剪策略^[43]防止梯度爆炸; 当训练总损失达到 1×10^5 后, 引入 L-BFGS 优化器进行训练至损失趋于稳定, 不同网络规模配置下的训练结果如图 2 所示, 训练最终得到的 Loss 值如表 1 所示:




图 2 不同隐藏层深度和宽度情况下总 Loss 变化趋势 (a) 2 层隐藏层的情况; (b) 3 层隐藏层的情况; (c) 4 层隐藏层的情况; (d) 5 层隐藏层的情况;

Fig.2. Total Loss variation trends under different hidden layer depths and widths (a) 2-layer hidden layer; (b) 3-layer hidden layer; (c) 4-layer hidden layer; (d) 5-layer hidden layer;

表1 不同隐藏层与神经元配置下得到的Loss
Table 1. Loss obtained under different hidden layer and neuron configurations

隐藏层	神经元	2	3	4	5
	16	1.2×10^{-6}	2.8×10^{-6}	8.4×10^{-7}	4.3×10^{-6}
	32	5.4×10^{-6}	6.4×10^{-6}	4.8×10^{-6}	4.9×10^{-6}
	64	3.4×10^{-6}	4.1×10^{-6}	2.1×10^{-6}	3.2×10^{-6}

从图 2 中可以观察到, 对于 RKS-PINN 模型, 当隐藏层从 2 层增加到 4 层时, 模型的训练过程随隐藏层数的增加变得更加稳定, 训练总损失值的波动性有小幅下降, 当隐藏层数达到 5 层, 波动性又有轻微上升趋势, 这可能是由于深层网络虽然理论上具备更强的表达能力, 但在相同优化策略下更容易陷入局部振荡。结合图 2 所示的不同神经网络参数设置下得到的 Loss 下降过程以及表 1 所示的 Loss 数据, 下文中 RKS-PINN 模型选取 4 隐藏层、每层 16 个神经元配置。

2.1.2 PR-PINN 模型

采用相同的策略对 PR-PINN 模型进行训练, 不同网络规模配置下的训练结果如图 3 所示, 训练最终得到的 Loss 值如表 2 所示:




图 3 不同隐藏层深度和宽度情况下总 Loss 变化趋势 (a) 2 层隐藏层的情况; (b) 3 层隐藏层的情况; (c) 4 层隐藏层的情况; (d) 5 层隐藏层的情况;
Fig.3. Total Loss variation trends under different hidden layer depths and widths (a) 2-layer hidden layer; (b) 3-layer hidden layer; (c) 4-layer hidden layer; (d) 5-layer hidden layer;

表2 不同隐藏层与神经元配置下得到的Loss
Table 2. Loss obtained under different hidden layer and neuron configurations

隐藏层	神经元	2	3	4	5
	16	4.6×10^{-6}	1.1×10^{-6}	8.8×10^{-7}	4.1×10^{-6}
	32	2.2×10^{-6}	3.2×10^{-6}	4.8×10^{-6}	5.2×10^{-6}
	64	2.1×10^{-6}	5.1×10^{-6}	5.2×10^{-6}	2.1×10^{-6}

从图 3 中可以观察到, 对于 PR-PINN 模型, 随着隐藏层数的增加, 模型的训练过程变得更加稳定, 训练总损失值的波动性有小幅下降, 当隐藏层数达到 5 层, 波动性又有上升趋势, 这一趋势跟 RKS-PINN 模型是类似的。结合表 2 中的数据, 后续 PR-PINN 模型选取 4 层隐藏层、16 个神经元的配置。

2.1.3 网络参数的稳定性与泛化性分析

为确保本研究中所构建模型的预测性能具有稳定性和可重复性,针对网络参数初始化的敏感性进行了系统性评估。对上节选取的超参数配置,重复独立训练 10 次,每次使用不同的随机种子以确保权重初始化完全独立。每次训练结束后,记录两个关键指标:一是最终收敛时的总损失值 ($Loss$),二是核心可训练参数 c 的预测值。从图 4 所示的波动曲线可见,在 10 次独立训练中, $Loss$ 值和可训练参数 c 的预测值受初始化扰动的影响极小。




图 4 重复训练 $Loss$ 值与预测值变化曲线 (a) RKS-PINN 模型; (b) PR-PINN 模型

Fig.4. Curves showing changes in training $Loss$ and prediction values: (a) RKS-PINN model; (b) PR-PINN model

为客观评估模型泛化能力,在独立验证集上计算预测压力的 MSE ,而非仅依赖训练损失。如图 5 所示,对比 12 种网络结构下 RKS-PINN 与 PR-PINN 的 MSE 表现,模型在多数配置下误差较低,尤其在(4,16)即 4 层 16 神经元和(5,32)即 5 层 32 神经元结构中 MSE 最小。综合计算成本与数据精度,同样选取 4 层 16 神经元用于后续训练,该配置具备良好的预测泛化性。




图5 模型在不同网络配置下的 MSE
Fig.5. MSE of the model under different network configurations

2.2 标准气体状态方程误差及 PINN 修正

在本节中研究方程约束神经网络模型精度，重点关注其在极端条件下的表现，并对方程约束神经网络模型在测试集上的表现进行定量分析。

2.2.1 RKS-PINN 模型

本小节研究 RKS-PINN 模型性能，利用 70 组压力、密度与温度数据对其进行数据驱动和物理约束修正，采用上节中得到的最优网络配置（4 隐藏层、16 神经元）进行 20000 次训练循环，得到的训练损失曲线如图 6 所示。




图6 RKS-PINN 模型训练损失曲线
Fig.6. Training Loss curve of the RKS-PINN model

RKS-PINN 模型训练最终得到的立方项系数 c 值为-0.000289，即修正后的状态方程（IRKS）公式如式（20）所示：

$$P = \frac{\rho RT}{1 - b\rho} - \frac{a\rho^2}{1 + b\rho} - 0.000289\rho^3, \quad (20)$$

表 3 展示了 IRKS 状态方程预测饱和水蒸气两相密度与实验值之间的误差（ δ ），误差计算式如公式（21）所示，公式中下标 *theory* 和 *EXP* 分别代表解析解和实验值：

$$\delta = \left| \frac{\rho_{\text{theory}} - \rho_{\text{EXP}}}{\rho_{\text{EXP}}} \right| \times 100\%,$$

(21)

表3 RKS状态方程修正前后误差比较
Table3. Comparison of errors before and after correction of the RKS state equation

气体状态方程	温度范围 T/k	气相平均相对误差	液相平均相对误差	两相平均误差
RKS	273.16~643.16	4.60%	23.72%	14.46%
IRKS	273.16~643.16	0.93%	12.44%	6.685%

为对比修正后状态方程的性能，表中也给出了未修正状态方程（RKS）得到的误差。从表 3 中数据可以发现，IRKS 方程在气相、液相及两相平衡状态下的平均相对误差均显著降低：平均气相误差由 4.60%降至 0.93%，液相误差由 23.72%下降至 12.44%，两相平衡误差则从 14.46%降低至 6.685%。整体预测精度提高了 7.775%，表明 IRKS 方程在高温高压条件下仍能准确捕捉实验数据的趋势。

为直观比较修正后状态方程计算值在不同压力和温度下的性能，图 7 给出了修正前后 RKS 方程在气液两相区的计算结果与实验数据（EXP）的对比情况。在气相区域，尽管密度的绝对误差较小，但由于蒸汽密度远低于液体密度，其相对误差可能显著增大。这一现象源于状态方程的物理特性：当温度远低于临界温度时，气相密度比会变得非常小，导致即使液体密度发生微小变化，也会引起蒸汽密度的较大波动^[32]。因此，为了更准确评估模型在气相区的表现，图 8 进一步给出了修正前后 RKS 方程在气相区域的预测对比情况。




图 7 RKS 方程气液相误差
Fig.7. Gas-liquid phase errors of the RKS equation




图 8 RKS 方程气相误差
Fig.8. Gas phase errors of the RKS equation

从图 7 中结果可以发现, 原始 RKS 方程在气液两相区域对密度的预测存在部分偏差, 尤其在临界点附近偏离实验值较大; 而修正后的 IRKS 方程 (蓝色实线) 显著改善了这一问题, 其预测曲线更贴近实验数据, 表现出更好的拟合能力。在图 8 所示气相区域, RKS 方程虽然整体趋势与实验数据一致, 但在临界区域仍存在一定误差, 而 IRKS 模型则进一步优化了预测精度, 更加贴合实验数据。这说明通过数据驱动方法修正后的状态方程不仅保留了传统模型的物理一致性, 还提升了模型在复杂工况下的预测能力, 特别是在相变边界和极端条件下的适用性更强。

对于 RKS-PINN 模型, 通过测试集上的预测结果与真实值的对比来进行评估, 具体结果如图 9 所示。其中, 图 9(a) 呈现的是三维空间中真实值与预测值的散点分布, 借助这一图表, 能够直观地观察到两者在整体空间分布上的契合程度; 图 9(b) 为二维平面上的拟合曲线, 通过该曲线可以清晰地了解模型对数据趋势的捕捉能力; 图 9(c) 则是预测误差的统计分布直方图, 通过分析该直方图, 能够量化地掌握预测误差的分布特征, 包括误差的集中范围、离散程度等, 进而综合判断 RKS-PINN 模型的预测性能。




图 9 RKS-PINN 测试集误差图 (a) 三维误差图; (b) 预测压力结果相关图; (c) 误差分布直方图

Fig.9. Error plot of the RKS-PINN test set: (a) 3D error plot; (b) Correlation plot of predicted pressure results; (c) Histogram of error distribution

为了客观评价 RKS-PINN 模型的预测性能, 采用以下三个常用的回归评估指标进行定量分析:

1. 均方误差 (MSE)

均方误差衡量预测值与真实值之间的平均平方差异, 是对预测误差大小的一种全局性度量。其定义如公式 (22) 所示:

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2, \quad (22)$$

其中, y_i 为第 i 个样本的真实值, $\hat{y}_i$ 为第 i 个样本的预测值, N 为样本总数。

2. 决定系数 (R^2)

决定系数反映了模型对目标变量变化的解释能力, 数值范围为 $[0, 1]$, 越接近于 1 表示模型拟合效果越好。其定义如公式 (23) 所示:

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}, \quad (23)$$

其中, $\bar{y}$ 表示真实值的平均值。

3. 平均绝对误差 (MAE)

平均绝对误差衡量预测值与真实值之间的平均绝对差异, 其定义如公式 (24) 所示:

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|, \quad (24)$$

由图 9(a) 的三维散点图可以看出, 测试集上的实验真实值 (蓝色圆点) 与 RKS-PINN 模型的预测

值（红色三角形）高度重合，尤其是在高压区域（高密度区），说明模型具有良好的预测能力。接着由图 9(b)的二维拟合图进一步验证了这一结论：预测值均匀分布在理想对角线附近，表明模型预测值与实验数据之间具有高度一致性。均方误差（ MSE ）为 0.000001，决定系数（ R^2 ）为 0.999994，平均绝对误差（ MAE ）为 0.000610，表明 RKS-PINN 模型具有较高的精度。最后由 9(c)的误差分布直方图可以看出，预测误差主要集中在较小范围内，误差分布集中且偏小。

2.2.2 PR-PINN 模型

接下来研究 PR-PINN 模型性能，同样利用 70 组压力、密度与温度数据对其进行数据驱动和物理约束修正，采用上节中得到的最优网络配置（4 隐藏层、16 神经元）进行 20000 次训练循环，得到的训练损失曲线如图 10 所示。




图 10 PR-PINN 模型训练损失曲线
Fig.10. Training Loss curve of the PR-PINN model

PR-PINN 模型训练最终得到的立方项系数 c 值为-0.0002316，即修正后的状态方程（IPR）公式如式（25）所示：

$$P = \frac{\rho RT}{1 - b\rho} - \frac{a\rho^2}{1 + 2b\rho - b^2\rho^2} - 0.0002316\rho^3, \tag{25}$$

表 4 展示了 IPR 状态方程预测饱和水蒸气两相密度与实验值之间的误差：

表4 PR状态方程修正前后误差比较
Table 4. Comparison of errors before and after correction of the PR state equation

气体状态方程	温度范围 T/k	气相平均相对误差	液相平均相对误差	两相平均误差
PR	273.16~643.16	3.62%	16.89%	10.46%
IPR	273.16~643.16	1.63%	10.37%	6.13%

为对比修正后状态方程的性能，表中也给出了未修正状态方程（PR）得到的误差。从表 4 中数据可以发现，IPR 方程在气相、液相及两相平衡状态下的平均相对误差均显著降低：平均气相误差由 3.62%降至 1.63%，液相误差由 16.89%下降至 10.37%，两相平衡误差则从 10.46%降低至 6.13%。整体预测精度提高了 4.33%，表明 IPR 方程在高温高压条件下仍能准确捕捉实验数据的趋势。

为直观比较修正后状态方程计算值在不同压力和温度下的性能，图 11 和图 12 分别给出了 PR 方程在气液相共存区和气相区域的预测结果与实验数据的对比情况。




图 11 PR 方程气液相误差
Fig.11. Gas-liquid phase errors of the PR equation




图 12 PR 方程气相误差
Fig.12. Gas phase errors of the PR equation

从图 11 中结果可以发现, 原始 PR 方程在气液两相区域对密度的预测存在偏差, 尤其在临界点附近时偏离实验值较大; 而修正后的 IPR 模型 (蓝色实线) 显著改善了这一问题, 其预测曲线更贴近实验数据, 表现出更好的拟合能力。在图 12 所示气相区域, PR 方程虽然整体趋势与实验数据一致, 但在临界区域仍存在一定误差, 而 IPR 模型则进一步优化了预测精度, 更加贴近实验值。

对于 PR-PINN 模型, 通过测试集上的预测结果与真实值的对比来进行评估, 具体结果如图 13 所示。该图包括三维空间中的真实值与预测值散点分布、二维平面上的拟合曲线以及预测误差的统计分布直方图。




图 13 PR-PINN 测试集误差图 (a) 三维误差图; (b) 预测压力结果相关图; (c) 误差分布直方图

Fig.13. Error plot of the PR-PINN test set: (a) 3D error plot; (b) Correlation plot of predicted pressure results; (c) Histogram of error distribution

由图 13(a)的三维散点图可以看出, 实验真实值 (蓝色圆点) 与 PR-PINN 模型的预测值 (红色三角形) 也表现高度重合, 说明模型具有良好的预测能力。接着由图 13(b)的二维拟合图进一步验证了这一结论: 预测值几乎全部分布在理想对角线附近, 表明模型预测值与实验数据之间具有高度一致性。均方误差 (MSE) 为 0.000001, 决定系数 (R^2) 为 0.999988, 平均绝对误差 (MAE) 为 0.000921, 表明 PR-PINN 模型具有较高的精度。最后由 13(c)的误差分布直方图也可以看出, 预测误差主要集中在较小范围内, 误差分布集中且偏小, 进一步验证了模型预测结果的稳定性和可靠性。

2.3 气体状态方程 p - V 曲线图

本节通过绘制等温线 (p - V 曲线) 对比 PINN 修正前后 RKS 和 PR 方程的预测性能。等温线反映恒温下压力与摩尔体积的关系, 能直观展现模型在不同工况、尤其是临界区的行为特征。

2.3.1. RKS 状态方程的 p - V 曲线

图 14 展示了原始及经 PINN 修正后的 RKS 状态方程在不同归一化温度 T/T_c 下的等温线 (含超临界区): 当低于临界温度时, 也就是 T/T_c 小于 1.0 的工况下, 修改前后的曲线变化趋势是相同的, 两者都可以较好地描述水蒸气的两相行为; 当处于临界温度时, 也就是 T/T_c 等于 1.0 的工况, 修正后的曲线转折点更加尖锐且更贴合实验数据点, 表明其对临界点附近非线性行为的捕捉能力显著增强。当处于超临界温度, 也就是 T/T_c 大于 1.0 的工况, 两者描述相同, 不再存在两相行为。可以看出, 修改后的 RKS 状态方程成功捕捉了临界点附近的非线性行为, 在描述流体行为时具有更高的准确性。




图 14 修正前后 RKS 方程 p - V 曲线 (a) 修正前 p - V 曲线; (b) 修正后 p - V 曲线

Fig.14. p - V Curves of the RKS Equation Before and After Correction: (a) p - V Curve Before Correction; (b) p - V Curve After Correction

2.3.2. PR 状态方程的 p - V 曲线

结合图 15 进行对比可见: 修改前后的 PR 方程在临界温度下均表现合理, 等温线呈典型双曲形特征, 能够基本捕捉流体行为趋势; 当处于临界温度时, 修改后曲线的转折点更加尖锐, 能够更准确

地捕捉临界点附近的特殊行为且紧密贴合实验数据点。当处于超临界温度时，两者描述相同，不再存在两相行为。




图 15 修正前后 PR 方程 p - V 曲线 (a) 修正前 p - V 曲线; (b) 修正后 p - V 曲线
Fig.15. p - V Curves of the PR Equation Before and After Correction: (a) p - V Curve Before Correction; (b) p - V Curve After Correction

可以看出, PINN 修正通过优化临界区域的曲线连续性、提升高压极端工况的拟合精度、增强超临界状态的预测稳定性,改善了状态方程的物理一致性与预测精度,尤其在临界点这一关键区域的性能提升最为突出。

3 结论

本文基于物理信息神经网络模型构建了求解气体状态方程热力学参数的数值模型,该模型将实验数据和物理定律嵌入深度学习神经网络,既保证了严格的物理定律一致性,又提高了模型的预测精度。通过对修正后状态方程性能和方程约束神经网络模型稳健性的讨论,得到了以下主要结论:

(1) 方程约束神经网络模型在 12 种不同配置网络结构下均能保持稳定的预测性能,具有良好的稳健性以及泛化能力。

(2) 经过 PINN 修正后,两种状态方程的预测性能得到了提升:修正后的 RKS 状态方程的两相平均预测误差降低到了 6.685%,修正后的 PR 状态方程的两相平均预测误差降低到了 6.13%。修正后气体状态方程在气相区以及临界区的预测精度得到较大提升,预测误差在 2%以内。

(3) RKS-PINN 模型的 MSE 为 0.000001, R^2 为 0.999994; PR-PINN 模型的 MSE 为 0.000001, R^2 为 0.999988,表明两种模型具有较高的精度。

(4) 在 p - V 曲线图中可以观察到 PINN 修正有效优化了 RKS 和 PR 状态方程在临界区域的曲线连续性,符合物理一致性。

本文中方程约束神经网络模型的研究以水蒸气为工质,基于 RKS 和 PR 两种状态方程展开,该方法通过物理约束与数据驱动相结合修正状态方程,可推广至其他类型的状态方程以及不同工质,具有良好的通用性。

参考文献

- [1] 郑建国, 马东军, 孙德军, 等. Van der Waals 状态方程可压缩多流体流动的 PPM 方法[J]. 计算物理, 2007, (03): 287-294.
- [2] SUN L, ELY J F. Universal equation of state for engineering application: algorithm and application to non-polar and polar fluids[J]. Fluid Phase Equilibria, 2004, 222: 107-118.
- [3] DE HEMPTINE J C, MOUGIN P, BARREAU A, et al. Application to petroleum engineering of statistical thermodynamics-based equations of state[J]. Oil & Gas Science and Technology-Revue de l'IFP, 2006, 61(3): 363-386.
- [4] VASILYEV A S, GARTMAN T N. Calculating the Critical Properties of Multicomponent Mixtures Using the Soave-Redlich-Kwong (SRK) and Peng-Robinson (PR) Equations of State, Based on the Binary Interaction Parameters[J]. Russian Journal of Physical Chemistry A, 2019, 93(4): 620-624.
- [5] CHEN X, LI H. Improved prediction of saturated and single-phase liquid densities of water through volume-translated SRK EOS[J]. Fluid Phase Equilibria, 2021, 528: 112852.
- [6] LUNDSTRØM C, MICHELSEN M L, KONTOGEORGIS G M, et al. Comparison of the SRK and CPA equations of state for physical

- properties of water and methanol[J]. *Fluid phase equilibria*, 2006, 247(1-2): 149-157.
- [7] ZOGHI A T, FEYZI F, ZARRINPASHNEH S, et al. Solubility of light reservoir gasses in water by the modified Peng-Robinson plus association equation of state using experimental critical properties for pure water[J]. *Journal of Petroleum Science and Engineering*, 2011, 78(1): 109-118.
- [8] LUO M J, MA P S, XIA S Q. A modification of α in SRK equation of state and vapor-liquid equilibria prediction[J]. *Chinese Journal of Chemical Engineering*, 2007, 15(1): 102-109.
- [9] HAJIZADEH N, MORADI G, ASHOORI S. Modified SRK equation of state for modeling asphaltene precipitation[J]. *International Journal of Chemical Reactor Engineering*, 2020, 18(3): 20190180.
- [10] LI H, YANG D. Modified α function for the Peng–Robinson equation of state to improve the vapor pressure prediction of non-hydrocarbon and hydrocarbon compounds[J]. *Energy & Fuels*, 2011, 25(1): 215-223.
- [11] ESLAMI L, KHADEM-HAMEDANI B. Development of a novel Peng–Robinson plus association equation of state for industrially important associating compounds[J]. *Neural Computing and Applications*, 2019, 31(7): 2107-2115.
- [12] FÖLL F, HITZ T, MÜLLER C, et al. On the use of tabulated equations of state for multi-phase simulations in the homogeneous equilibrium limit[J]. *Shock Waves*, 2019, 29(5): 769-793.
- [13] RAISSI M, PERDIKARIS P, KARNIADAKIS G E. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations[J]. *Journal of Computational physics*, 2019, 378: 686-707.
- [14] MAO Z, JAGTAP A D, KARNIADAKIS G E. Physics-informed neural networks for high-speed flows[J]. *Computer Methods in Applied Mechanics and Engineering*, 2020, 360: 112789.
- [15] ALIAKBARI M, MAHMOUDI M, VADASZ P, et al. Predicting high-fidelity multiphysics data from low-fidelity fluid flow and transport solvers using physics-informed neural networks[J]. *International Journal of Heat and Fluid Flow*, 2022, 96: 109002.
- [16] HE A, SHI J, CHEN J J, et al. The data-driven solutions and inverse problems of some nonlinear diffusion convection-reaction equations based on Physics-Informed Neural Network[J]. *Physica Scripta*, 2024, 99(11): 116001.
- [17] LV S J, LI D L, ZHA W S, et al. Solving seepage equation using physics-informed residual network without labeled data[J]. *Computer Methods in Applied Mechanics and Engineering*, 2024, 418: 116563.
- [18] 刘东, 陈奇隆, 王雪强. 线性积分方程原函数变换深度学习求解方法[J]. *计算物理*, 2024, 41 (05): 651-662.
- [19] 刘子岩, 许亮. 嵌入物理约束的可压缩多介质神经网络模型[J]. *计算物理*, 2023, 40 (06): 761-769.
- [20] 陈周纬宇, 任翔, 张飞舟, 等. 基于残差神经网络的激光转塔气动光学效应快速预测[J]. *计算物理*, 2025, 42 (02): 160-170.
- [21] CHEN F X, LUO S, WANG S H, et al. A generalized machine learning-assisted phase-equilibrium calculation model for shale reservoirs[J]. *Fluid Phase Equilibria*, 2022, 558: 113423.
- [22] CHENG J X, LU J X, LIU B J, et al. A Hybrid Mechanism and Data-Driven Approach for Predicting Fatigue Life of MEMS Devices by Physics-Informed Neural Networks[J]. *Fatigue & Fracture of Engineering Materials & Structures*, 2025, 48(1): 3-15.
- [23] 薛社生, 朱希睿. 真实气体的一种近似冲击波关系式[J]. *计算物理*, 2024, 41 (03): 308-315.
- [24] 周梦, 陶应奇, 周晓云, 等. 含能离子盐 TKX-50 状态方程及热力学性质的第一性原理研究[J]. *计算物理*, 2024, 41 (04): 487-493.
- [25] YOKOZEKI A, SHIFLETT M B. Gas solubilities in ionic liquids using a generic van der Waals equation of state[J]. *The Journal of Supercritical Fluids*, 2010, 55(2): 846-851.
- [26] CISMONTI M, MOLLERUP J. Development and application of a three-parameter RK–PR equation of state[J]. *Fluid Phase Equilibria*, 2005, 232(1-2): 74-89.
- [27] SOAVE G. Equilibrium constants from a modified Redlich-Kwong equation of state[J]. *Chemical engineering science*, 1972, 27(6): 1197-1203.
- [28] PENG D Y, ROBINSON D B. A new two-constant equation of state[J]. *Industrial & Engineering Chemistry Fundamentals*, 1976, 15(1): 59-64.
- [29] SINHA S S, GHOSH A, RAY D S. Fluctuation corrections to thermodynamic functions: Finite-size effects[J]. *Physical Review E—Statistical, Nonlinear, and Soft Matter Physics*, 2013, 87(4): 042112.
- [30] HAGHTALAB A, KAMALI M J, MAZLOUMI S H, et al. A new three-parameter cubic equation of state for calculation physical properties and vapor–liquid equilibria[J]. *Fluid Phase Equilibria*, 2010, 293(2): 209-218.
- [31] KUMAR A, UPADHYAY R. A new two-parameters cubic equation of state with benefits of three-parameters[J]. *Chemical Engineering Science*, 2021, 229: 116045.
- [32] TRUNG D D. Development of data normalization methods for multi-criteria decision making: applying for MARCOS method[J]. *Manufacturing review*, 2022, 9: 2022019.
- [33] YUAN P, SCHAEFER L. Equations of state in a lattice Boltzmann model[J]. *Physics of fluids*, 2006, 18(4): 042101.
- [34] RUPPEINER G. Thermodynamic curvature from the critical point to the triple point[J]. *Physical Review E—Statistical, Nonlinear, and Soft Matter Physics*, 2012, 86(2): 021130.
- [35] CHEN Y L, CHEN Q, MA H, et al. Transfer machine learning framework for efficient full-field temperature response reconstruction of thermal protection structures with limited measurement data[J]. *International Journal of Heat and Mass Transfer*, 2025, 242: 126785.
- [36] KALAISELVI T, PADMAPRIYA S T, SOMASUNDARAM K, et al. E-Tanh: a novel activation function for image processing neural network models[J]. *Neural Computing and Applications*, 2022, 34(19): 16563-16575.
- [37] SARI M, GULEN S, CELENK P. Various optimized artificial neural network simulations of advection-diffusion processes[J]. *Physica Scripta*, 2024, 99(11): 116016.
- [38] TOWNSEND J P, SHOHET G, COCHRANE K R. Liquid-Vapor Coexistence and Critical Point of Mg_2SiO_4 From Ab Initio Simulations[J]. *Geophysical Research Letters*, 2020, 47(17): e2020GL089599.
- [39] GUO L, KAI-LAI X. Automatic differentiation and its applications in physics simulation[J]. *ACTA PHYSICA SINICA*, 2021, 70(14): 149402.
- [40] MOCHALIN I, WANG J, CAI J. Enhancement of physics-informed neural networks in applications to fluid dynamics[J]. *Physics of Fluids*, 2025, 37(5): 057130.
- [41] BLAKE C, FORD C, MANNER B, et al. Improving the Adam optimizer using time delays[J]. *Nonlinearity*, 2025, 38(7): 075030.
- [42] LI Y F, SHI Q Z, LI Y, et al. High-resolution bone microstructure imaging based on ultrasonic frequency-domain full-waveform inversion[J]. *Chinese Physics B*, 2021, 30(1): 014302.
- [43] SUN H J, ZHOU W, YANG J P, et al. An improved medical image classification algorithm based on Adam optimizer[J]. *Mathematics*, 2024,

12(16): 2509.

